Propuesta de proyecto MiBici — Equipo 23

TC5061 — Operaciones de aprendizaje automático — Equipo 23

Octubre 2026

Enlace al repositorio oficial: https://github.com/bryan-s-ortega/TC5061-Proyecto-Equipo23

Integrantes del Equipo 23:

- **Miguel Ángel Durán Betancourt** — A01797974
- **Juan Pablo Islas Guzmán** — A01797727
- **Bryan Steve Ortega Castillo** — A01797846
- **Kevin Rogelio Rodriguez Magaña** — A01840418

---

1. Formulación del Problema y ML Canvas

El sistema de bicicleta pública del Área Metropolitana de Guadalajara (MiBici) enfrenta tres retos operacionales críticos de asignación de recursos y diseño de red. A continuación se formulan los tres problemas siguiendo el marco del *Machine Learning Canvas*:

Dimensión	Pregunta 1 (P1): Demanda Diaria	Pregunta 2 (P2): Riesgo de Desbalance	Pregunta 3 (P3): Segmentación de Estaciones
Tipo de Tarea	Aprendizaje Supervisado (Regresión)	Aprendizaje Supervisado (Clasificación Multiclase)	Aprendizaje No Supervisado (Clustering)
¿Qué se predice o agrupa?	Número total de viajes iniciados por día en la red de MiBici.	Nivel de presión operativa de la estación en el siguiente intervalo: sin presión, presión sin bicicletas (vacía) o presión sin anclajes (llena).	Tipología y perfil funcional de las estaciones físicas según sus patrones horarios, flujo neto y uso semanal.
Granularidad	Red completa, agregación diaria ($t = 1$ día).	Por estación individual, intervalos de 30 minutos ($t = 30$ min).	Por estación individual, matriz agregada para las 471 estaciones activas.
Horizonte	Pronóstico para las siguientes 24 horas ($H = 1$ día).	Pronóstico para los siguientes 30 minutos ($H = 30$ min).	Agrupamiento estacional y estratégico (semestral/anual).
Relevancia Operativa	Dimensionar la capacidad operativa general, turnos de mecánicos y disponibilidad global de unidades.	Prevenir el colapso operativo por estaciones sin bicicletas disponibles o sin anclajes libres para retorno.	Comprender la estructura funcional urbana del AMG y la complementariedad entre estaciones.

Dimensión	Pregunta 1 (P1): Demanda Diaria	Pregunta 2 (P2): Riesgo de Desbalance	Pregunta 3 (P3): Segmentación de Estaciones
Usuario del Resultado	Dirección de Operaciones y Mantenimiento de MiBici.	Supervisores logísticos de balanceo dinámico y conductores de camionetas.	Dirección General de AMIM y Dirección de Planeación Urbana y Transporte.
Decisión que se toma	Asignar la flota activa diaria, planear mantenimiento en taller y coordinar guardias de personal.	Despachar camionetas de rebalanceo hacia estaciones críticas antes de que queden bloqueadas.	Diseñar rutas fijas de rebalanceo (pares complementarios) y planificar expansión física de ciclovías y anclajes.

---

2. Definición de los Datos y Estrategia de Partición

2.1. Fuentes y Rango de Fechas

- **Fuente Oficial:** Portal de Datos Abiertos de MiBici.
- **Rango Seleccionado:** De **noviembre de 2023 a septiembre de 2026** (últimos 3 años operativos completos). Se justifica este periodo para asegurar suficiente representatividad pospandemia, capturar ciclos estacionales anuales y considerar la red madura de estaciones en el AMG.
- **Tamaño Real Obtenido:**
  - **Viajes procesados:** Más de 11.2 millones de viajes válidos.
  - **Estaciones activas:** 471 estaciones con coordenadas geográficas y capacidades válidas en el catálogo `stations_nomenclature.csv`.
  - **Almacenamiento columnar limpio:** 391 MB en formato Apache Parquet (`data/processed/trips.parquet`).

2.2. Variables Originales y Construcción del Target

- **Variables Originales de Viaje:** `trip_id`, `started_at`, `ended_at`, `origin_station_id`, `destination_station_id`, `user_id`, `gender`, `birth_year`.
- **Variables del Catálogo de Estaciones:** `id`, `name`, `latitude`, `longitude`, `dpcapacity`.
- **Construcción de Variables Objetivo:**
  - **Target P1:** Conteo total de viajes con `started_at` normalizado por día calendario (`viajes`), rellenando fechas con calendario continuo para detectar días sin servicio y rezagos temporales exactos.
  - **Target P2:** Proxy de presión neta por estación e intervalo de 30 minutos: se calculan las salidas y llegadas netas en relación con la capacidad física (`dpcapacity`). Si el déficit o superávit proyectado supera el umbral del 30% de capacidad, se clasifica como *presión sin bicicletas* o *presión sin anclajes*.
  - **Target P3:** No supervisado. La matriz de features describe la firma temporal: proporciones de uso matutino (07:00–10:00), mediodía (12:00–16:00), vespertino (17:00–21:00), fin de semana y ratio de flujo neto $(\text{llegadas} - \text{salidas})/(\text{llegadas} + \text{salidas})$.

2.3. Condiciones de Uso y Protección de Datos Personales

Los datos son publicados bajo licencia de datos abiertos para fines analíticos y de investigación. Se aplica estricta disociación: los identificadores de usuario (`user_id`), género y año de nacimiento se excluyen de la modelación y no se serializan ni exponen en ningún punto del pipeline, preservando el secreto estadístico y la privacidad.

2.4. Estrategia de Partición (Sin Fuga de Información Futura)

Para evitar la fuga de información temporal (*data leakage*): * Se prohíbe el muestreo aleatorio (*random split*). * Se aplica **partición cronológica estricta**: * **P1:** 80% inicial para entrenamiento cronológico ($n = 818$ días) y 20% más reciente para prueba ($n = 205$ días: marzo a septiembre de 2026). * **P2:** Entrenamiento hasta enero de 2026, validación de enero a junio de 2026 y prueba retenida de julio a septiembre de 2026. Todas las características rezagadas (`departures_prev_30m`, `arrivals_prev_2h`) se calculan estrictamente con eventos anteriores al inicio de la ventana de predicción.

---

3. Pipeline de ML e Ingesta Reproducible

El pipeline se ejecuta de extremo a extremo sin intervención manual:

1. **Ingesta (`mibici.dataset`):** Proceso CLI en Typer que descarga directamente los CSV mensuales del portal, valida codificaciones mixtas (`utf-8`, `latin-1`), normaliza encabezados, castea tipos de fecha y escribe el dataset consolidado en `data/processed/trips.parquet`.
2. **Versionado de Datos:** Se rastrea en DVC con `dvc.yaml` y `dvc.lock` apuntando a Google Cloud Storage (`gs://mibici-mlops-project`). Se complementa con `references/data_manifest.csv` para auditoría de integridad basada en hashes SHA-256 de cada archivo fuente.
3. **Feature Engineering Modular (`mibici.features`):** Funciones documentadas y modulares que generan las matrices temporales y espaciales reutilizables para P1, P2 y P3.

```
# Ingesta reproducible automática
uv sync
uv run dvc repro --force dataset
```

---

4. Baselines, Modelos Candidatos y Métricas por Pregunta

Pregunta	Modelo Baseline	Modelo Candidato	Métricas Propuestas	Justificación de las Métricas
P1	**Lag 7 (Autorregresivo Semanal):** Asume que la demanda de hoy replica la del mismo día de la semana anterior.	**RandomForestRegressor:** Ensamble de 200 árboles regularizados (`max_depth=6` , `min_samples_leaf=8`).	**MAE, RMSE,** R^2	El **MAE** refleja directamente el error promedio en número de viajes diarios (interpretable para el operador). El **RMSE** penaliza grandes desvíos y el R^2 mide la varianza explicada.
P2	**Regla de Clase Mayoritaria:** Predice siempre la clase mayoritaria (*sin presión*).	**DecisionTreeClassifier:** Árbol de profundidad 5 balanceado (`class_weight='balanced'`).	**Accuracy, F1 Macro, Recall**	En un problema de desbalance, el Accuracy es engañoso. El **F1 Macro** equilibra precisión y exhaustividad entre las 3 clases, y el **Recall** en las clases minoritarias de saturación es vital para no omitir alertas de desbalance.
P3	**K-Means Básico ($k = 4$):** Agrupamiento basado en 5 variables simples (escala y coordenadas geográficas).	**K-Means Enriquecido ($k = 4$) y Clustering Aglomerativo:** Espacio funcional 9D con dinámicas horarias y balance de flujo.	**Silhouette Score, Davies-Bouldin, Calinski-Harabasz**	El **Silhouette** mide compacidad y separación intracluster. **Davies-Bouldin** (menor es mejor) valida la separación de centroides respecto al diámetro de cluster. **Calinski-Harabasz** evalúa la dispersión entre clusters.

5. Diagrama de Arquitectura del Sistema

La arquitectura desacopla el almacenamiento de datos, el procesamiento de transformaciones y el gobierno de experimentos:

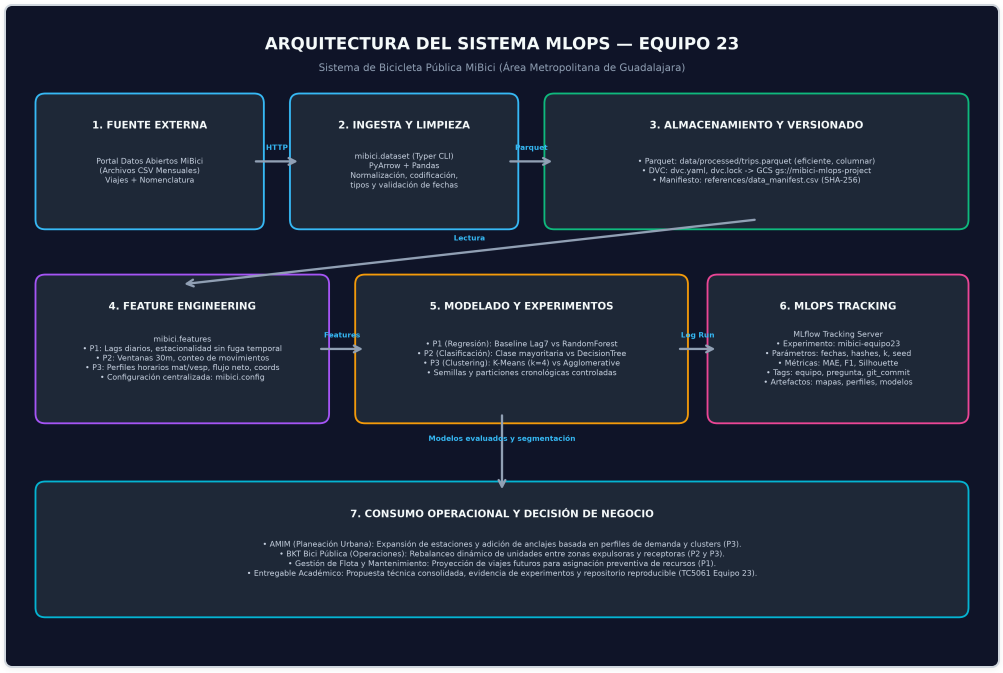


Diagrama de Arquitectura del Sistema MLOps — Equipo 23

Justificación de las Herramientas Seleccionadas:

- **uv:** Administrador de paquetes y entornos virtuales en Rust con resolución determinista mediante `uv.lock`. Reduce los tiempos de instalación de minutos a segundos y garantiza reproducibilidad idéntica.
- **Apache Parquet & PyArrow:** Formato columnar con compresión Snappy y tipado binario. Permite consultar millones de registros de viajes consumiendo solo ~390 MB y permitiendo streaming por lotes sin saturar la memoria RAM.
- **DVC + Google Cloud Storage:** Separa el código (Git) de los datos pesados (Cloud Storage), permitiendo sincronizar snapshots reproducibles de datos grandes sin degradar el rendimiento del repositorio.
- **MLflow Tracking:** Plataforma de gobernanza que audita y registra parámetros, métricas, artefactos y el commit exacto de Git (`git_commit`) en cada corrida.
- **Scikit-learn:** Biblioteca de referencia para modelado, garantizando algoritmos estandarizados y evaluadores rigurosos.
- **Ruff & Pre-commit:** Linter y formateador ultrarrápido que impone estándares PEP 8 y orden de imports antes de cada commit.

---

6. Resultados del Experimento Base y Modelos Candidatos

Resultados obtenidos sobre los conjuntos de prueba cronológicos con datos reales de MiBici:

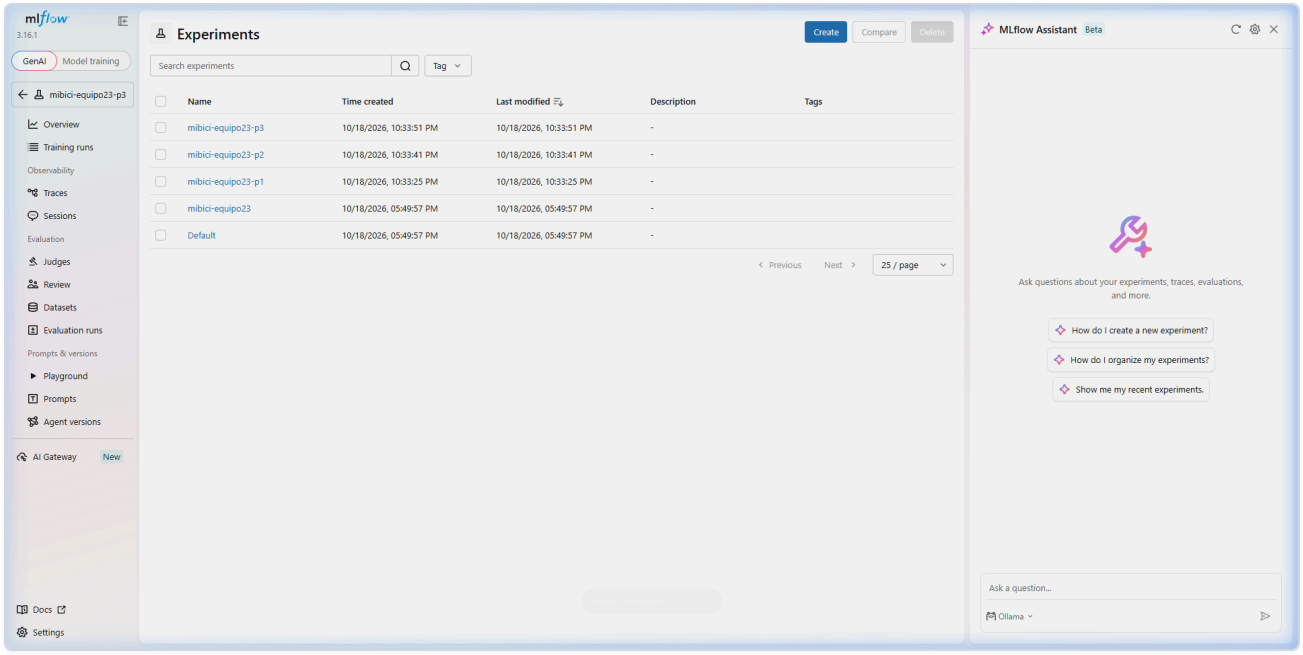
Pregunta	Experimento en MLflow	Modelo Evaluado	Métrica Principal	Métrica Secundaria	Conclusión Operativa
P1	`mibici-equipo23-p1`	**Baseline Lag 7**	MAE: 1,315.2 viajes	RMSE: 1,979.5 (R^2: 0.569)	Captura estacionalidad semanal básica.
P1	`mibici-equipo23-p1`	**RandomForest Candidato**	**MAE: 1,243.1 viajes**	**RMSE: 1,919.5 (R^2: 0.595)**	**Supera al baseline:** reduce el error medio en más de 72 viajes diarios y mejora el R^2.
P2	`mibici-equipo23-p2`	**Baseline Clase Mayoritaria**	Accuracy: 0.6244	F1 Macro: 0.7688	Incapaz de detectar eventos de saturación crítica.
P2	`mibici-equipo23-p2`	**Árbol de Decisión Candidato**	**Accuracy: 0.8282**	**F1 Macro: 0.8499**	**Supera al baseline:** mejora la exactitud en +20 puntos y permite predecir saturaciones.
P3	`mibici-equipo23-p3`	**K-Means Baseline ($k = 4$)**	Silhouette: 0.2990	Davies-Bouldin: 1.1685	Agrupa solo por tamaño y coordenadas espaciales (ciego a dinámicas horarias).
P3	`mibici-equipo23-p3`	**K-Means Candidato ($k = 4$)**	Silhouette: 0.1834	Davies-Bouldin: 1.7041	**Modelo funcionalmente superior:** descubre la asimetría real (polos laborales vs residenciales).

---

7. Evidencia de Corridas en MLflow

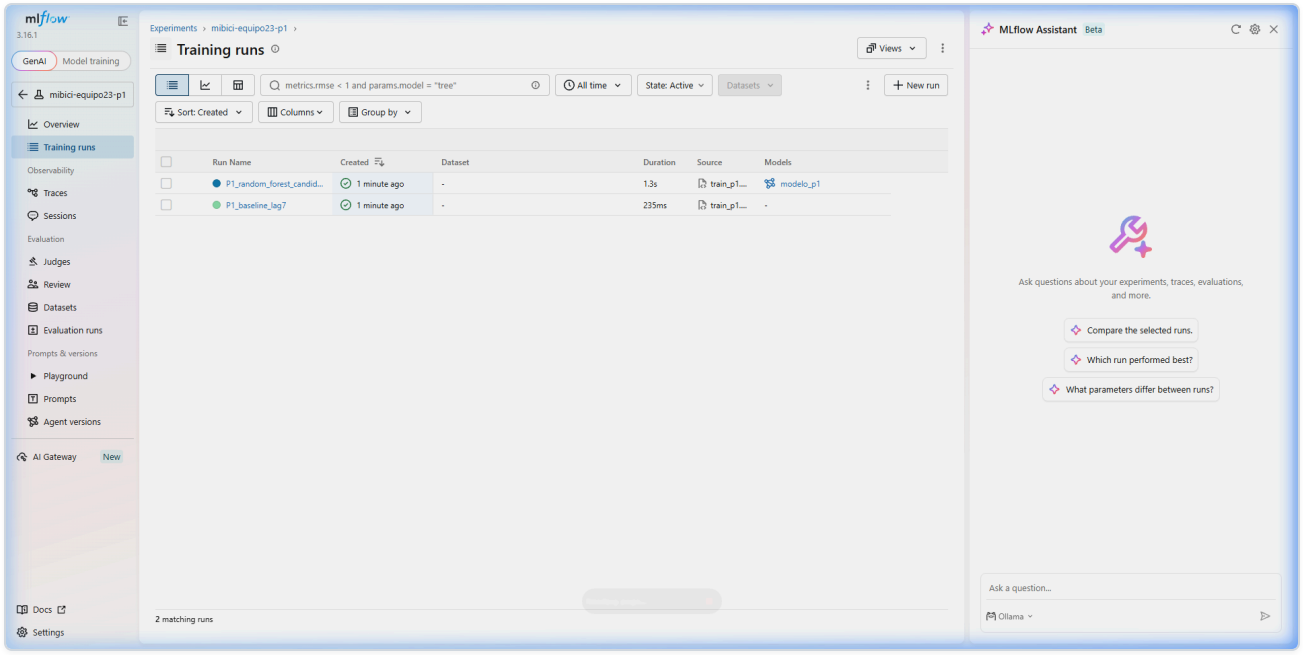
Se configuraron experimentos independientes por pregunta bajo el servidor local de MLflow (`sqlite:///mlruns.db` en el puerto 5001), registrando parámetros, métricas, etiquetas y artefactos:

7.1. Lista de Experimentos por Pregunta



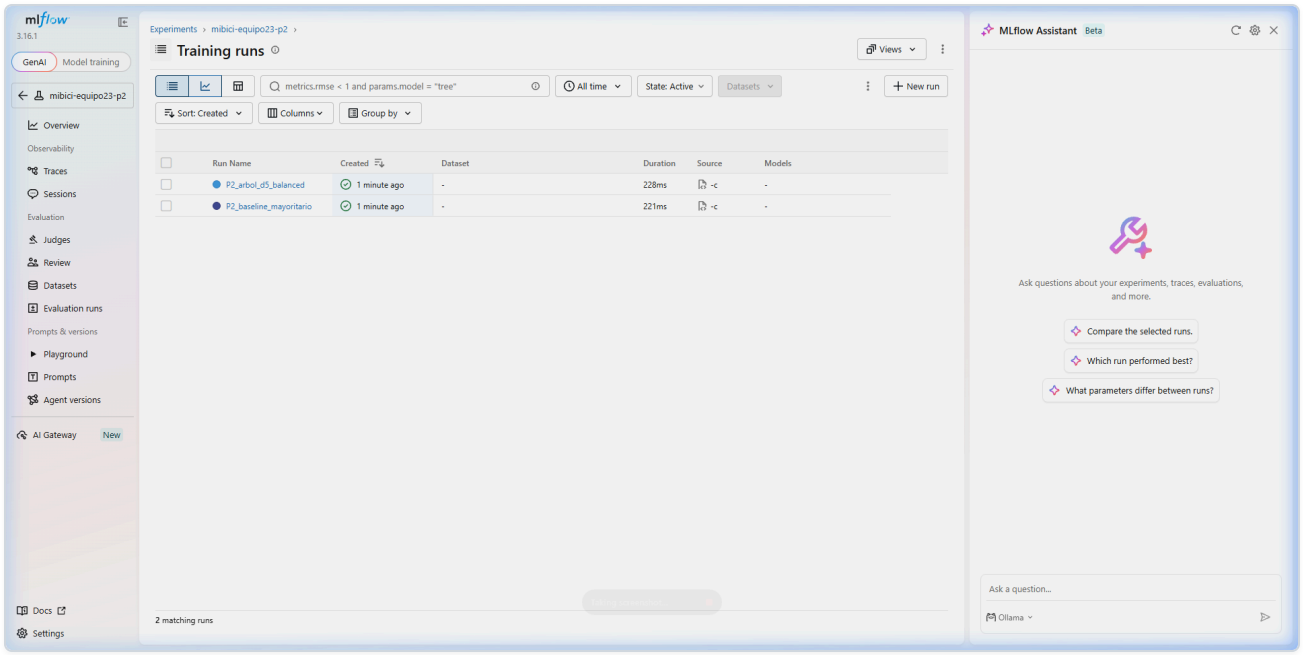
Experimentos creados por pregunta

7.2. Experimento P1 (Regresión de Demanda Diaria)



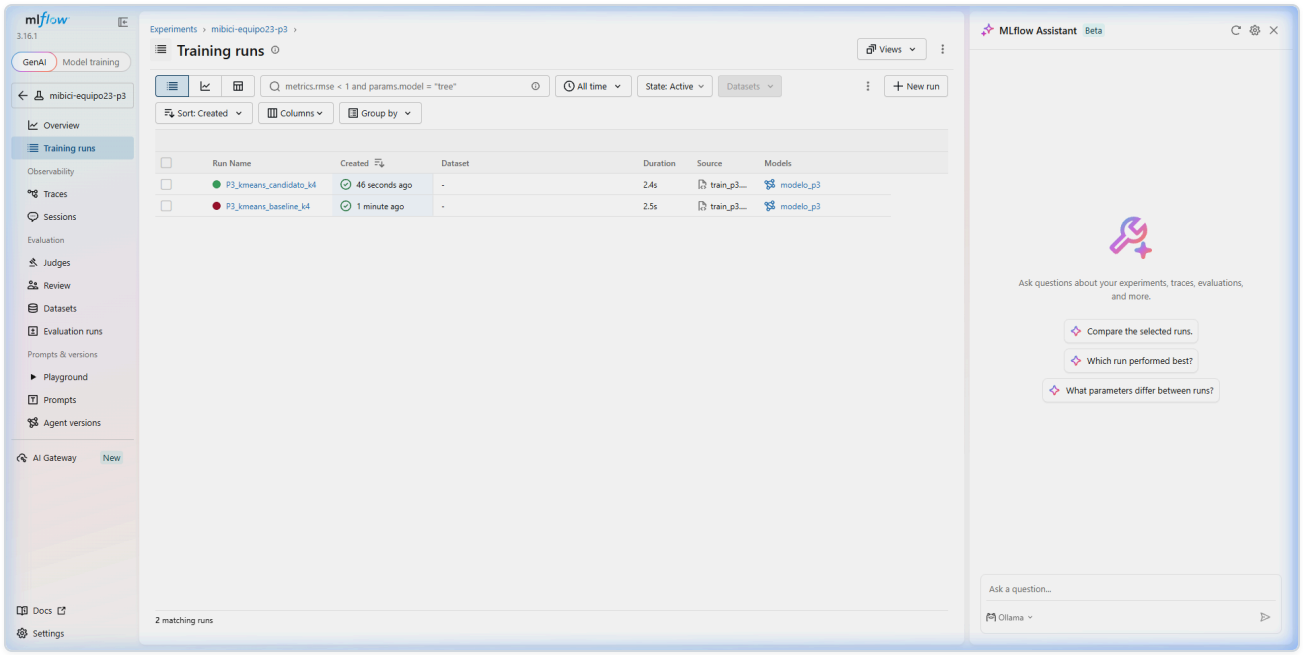
Corridas de P1 en MLflow

7.3. Experimento P2 (Clasificación de Riesgo de Desbalance)



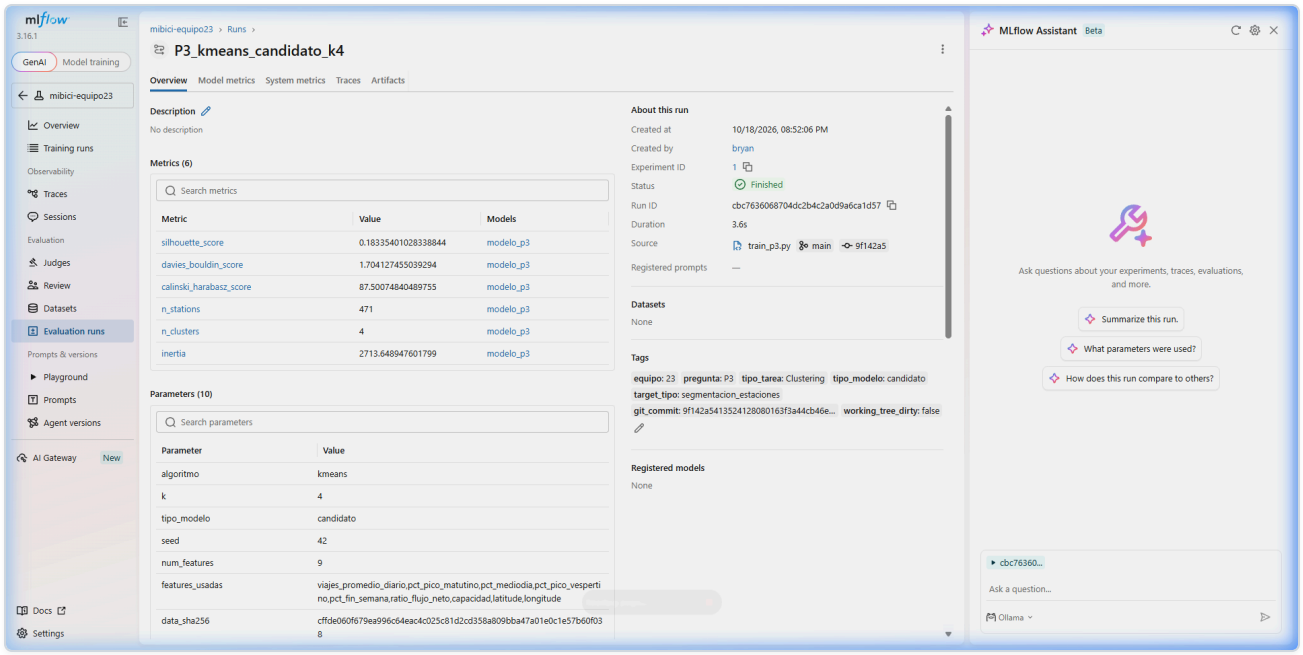
Corridas de P2 en MLflow

7.4. Experimento P3 (Clustering de Estaciones)



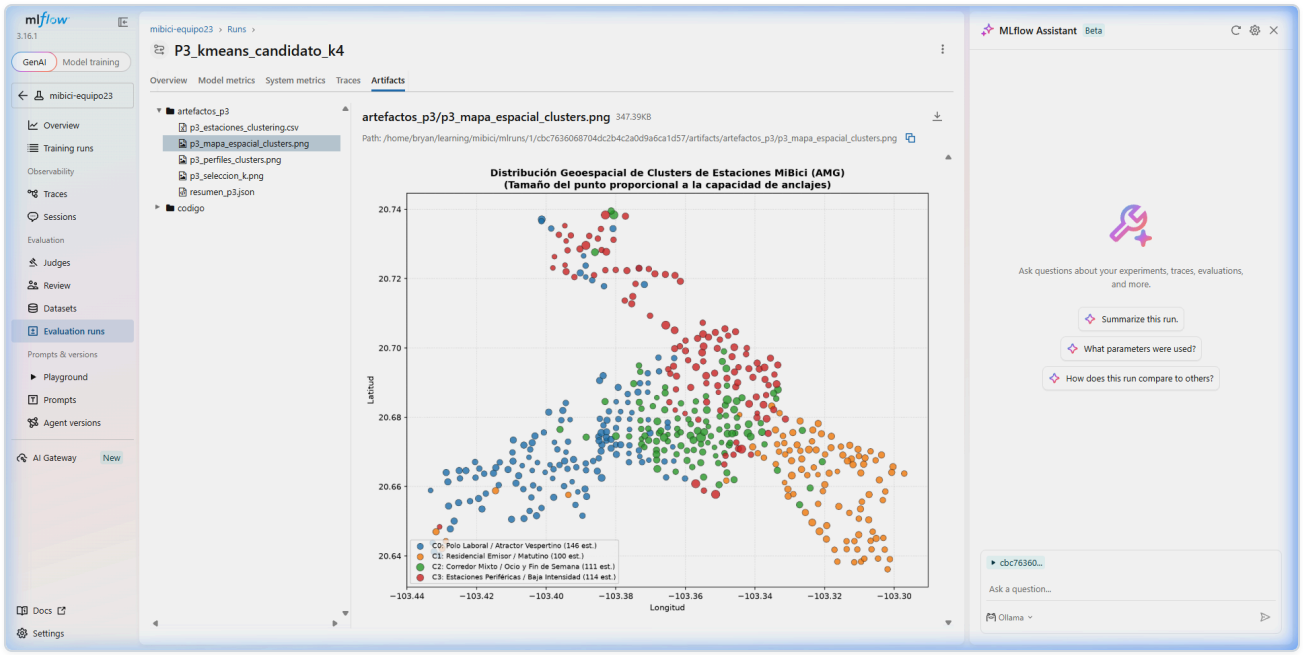
Corridas de P3 en MLflow

7.5. Detalle de Corrida con Etiquetas, Parámetros y Métricas



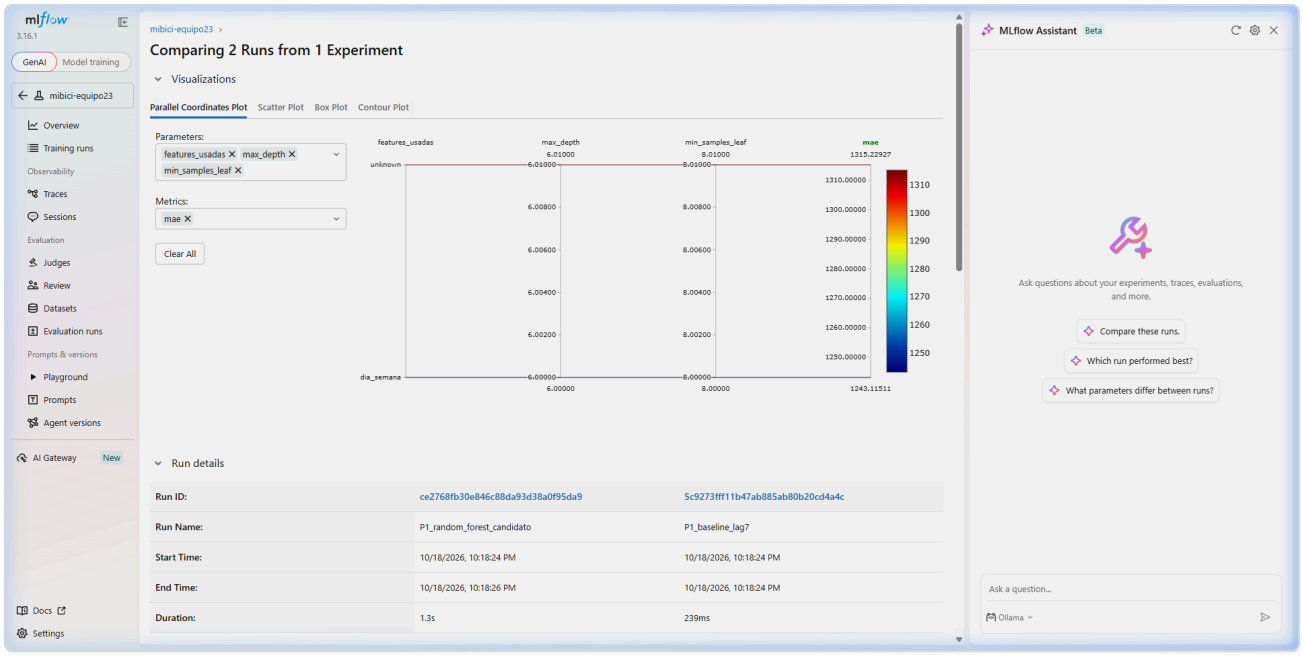
Detalle de corrida en MLflow

7.6. Artefactos Visuales Registrados en MLflow



Artefactos registrados en MLflow

7.7. Comparación de Corridas Lado a Lado



Comparación de corridas en MLflow

---

8. Estructura del Repositorio

El proyecto implementa la estructura estandarizada de *Cookiecutter Data Science (ccds)* gestionada con `uv`. A continuación se presenta el árbol verificado del repositorio:

```
TC5061-Proyecto-Equipo23/
├── .gitignore                          <- Excluye datos, modelos, mlruns y credenciales
├── .pre-commit-config.yaml             <- Hooks de calidad de código (ruff-check, ruff-format)
├── LICENSE                             <- Licencia del proyecto
├── README.md                           <- Documentación principal y guía de reproducción
├── TC5061_Propuesta_Proyecto_Equipo23.pdf <- Entregable formal consolidado en PDF
├── Taskfile.yml                        <- Automatización de tareas de desarrollo
├── data/
│   ├── external/                       <- Datos de terceros
│   ├── interim/                        <- Datos intermedios de transformación
│   ├── processed/                      <- trips.parquet versionado con DVC
│   └── raw/                            <- stations_nomenclature.csv
├── docs/                               <- Documentación técnica complementaria
│   ├── P3_CLUSTERING.md                <- Documento de segmentación de estaciones
│   └── README.md
├── dvc.lock                            <- Bloqueo determinista de artefactos DVC
├── dvc.yaml                            <- Pipeline de ingesta reproducible
├── mibici/                             <- Módulo principal del proyecto en Python
│   ├── __init__.py
│   ├── baseline_p2.py                  <- Baseline mayoritario de P2 por bloques
│   ├── build_p2_examples.py            <- Generación de ejemplos de clasificación
│   ├── build_p2_movements.py           <- Agregación de movimientos de estaciones
│   ├── config.py                       <- Centralización de rutas, semillas y constantes
│   ├── dataset.py                      <- Pipeline CLI de descarga e ingesta
│   ├── features.py                     <- Transformaciones y feature engineering
│   ├── modeling/
│   │   ├── __init__.py
│   │   ├── train_p1.py                 <- Entrenamiento y registro de P1
│   │   ├── train_p2.py                 <- Entrenamiento de árboles de P2
│   │   └── train_p3.py                 <- Clustering y registro de P3
│   └── plots.py
├── models/                             <- Modelos serializados (excluidos de Git)
├── notebooks/
│   ├── 0_exploracion-datos-mibici.ipynb <- Análisis exploratorio completo de datos
│   ├── mibici_propuesta_base.ipynb     <- Prototipos exploratorios iniciales
│   └── preparacion_p1.py               <- Extracción de serie diaria
├── pyproject.toml                      <- Configuración del proyecto y dependencias
├── references/                         <- Documentos de soporte y canvas
│   ├── ML Canvas Template.docx
│   ├── arquitectura_sistema.md         <- Justificación técnica de la arquitectura
│   ├── data_manifest.csv               <- Auditoría criptográfica SHA-256 de archivos
│   ├── diagrama_arquitectura.png       <- Diagrama de arquitectura del sistema
│   ├── evidencia_mlflow.md             <- Bitácora de registro en MLflow
│   ├── fuentes.md                      <- Enlaces y fuentes mensuales
│   ├── ml_canvas.md                    <- Machine Learning Canvas consolidado
│   ├── propuesta_entrega.md            <- Fuente de este reporte
│   └── referencias_apa7.md             <- Referencias bibliográficas
├── reports/
│   ├── evidence/                       <- Capturas oficiales de MLflow y auditoría
│   │   ├── estructura_repositorio.txt  <- Árbol plano verificado
│   │   ├── mlflow_artefactos.png       <- Vista de artefactos registrados
│   │   ├── mlflow_comparacion_runs.png <- Comparación de corridas
│   │   ├── mlflow_detalle_run.png      <- Parámetros, métricas y tags
│   │   ├── mlflow_experimento_p1.png   <- Runs del experimento P1
│   │   ├── mlflow_experimento_p2.png   <- Runs del experimento P2
│   │   ├── mlflow_experimento_p3.png   <- Runs del experimento P3
│   │   └── mlflow_experimentos_lista.png <- Lista general de experimentos
│   └── figures/                        <- Gráficas de diagnóstico y mapas
│       ├── p1_errores.png
│       ├── p1_real_vs_predicho.png
│       ├── p3_estaciones_clustering.csv
│       ├── p3_mapa_espacial_clusters.png
│       ├── p3_perfiles_clusters.png
│       ├── p3_seleccion_k.png
│       └── resumen_p3.json
├── tests/                              <- Pruebas unitarias automatizadas con pytest
│   ├── test_data.py
│   ├── test_p2_dates.py
│   ├── test_p2_features.py
│   └── test_p3.py
└── uv.lock                             <- Bloqueo estricto de 272 dependencias
```

9. Referencias (APA 7)

- AMIM. (2026). *Plan integral de movilidad y transporte sustentable del Área Metropolitana de Guadalajara*. Agencia Metropolitana de Infraestructura para la Movilidad.
- DrivenData. (2026). *Cookiecutter Data Science: A logical, reasonably standardized, but flexible project structure for doing and sharing data science work*. https://cookiecutter-data-science.drivendata.org/
- Iterative. (2026). *Data Version Control (DVC) Documentation*. https://dvc.org/doc
- MiBici. (2026). *Datos abiertos del sistema de bicicletas públicas de Guadalajara*. Gobierno del Estado de Jalisco. https://mibici.net/es/datos-abiertos/
- MLflow. (2026). *MLflow: An open source platform for the machine learning lifecycle*. https://mlflow.org/docs/latest/
- Scikit-learn developers. (2026). *Model evaluation: Quantifying the quality of predictions*. Scikit-learn User Guide. https://scikit-learn.org/stable/modules/model_evaluation.html