Propuesta de proyecto MiBici — Equipo 23

TC5061

17 de octubre de 2026

Repositorio del equipo: https://github.com/bryan-s-ortega/MiBici

Integrantes

- Miguel Ángel Durán Betancourt
- Juan Pablo Islas Guzmán — A01797727
- Bryan Steve Ortega Castillo
- Kevin Rogelio Rodriguez Magaña

1. Problema y propuesta

El proyecto propone una solución reproducible de Machine Learning para las tres preguntas operativas de MiBici:

Pregunta	Tarea	Usuario	Decisión
P1. ¿Cuántos viajes se iniciarán?	Regresión	Operador	Asignar flota y personal
P2. ¿Habrá riesgo de saturación?	Clasificación	Rebalanceo	Priorizar inspección o traslado
P3. ¿Qué estaciones comparten patrones?	Clustering	Planeación urbana	Detectar perfiles y zonas

La unidad de análisis es estación-día para P1 y P2, y estación-periodo para P3. P1 predice los viajes del día siguiente. P2 construye una etiqueta proxy de riesgo futuro a partir de demanda/capacidad, porque los datos abiertos no contienen inventario histórico real. P3 agrupa estaciones por uso, capacidad y ubicación.

2. Datos, uso y versionado

La fuente es el portal oficial de Datos abiertos de MiBici. Se descargaron 21 archivos de viajes, de enero de 2025 a septiembre de 2026, y el catálogo `nomenclatura_2026_09.csv`. La consolidación contiene 7,894,097 viajes y 484 estaciones.

El proyecto usa las variables de viaje necesarias para fechas, horas, origen, destino y duración, además de capacidad, latitud y longitud del catálogo. Los identificadores de usuario no se usan como variables ni se publican.

Los CSV grandes no se suben a Git. El mecanismo principal de versionado es DVC, con `dvc.yaml`, `dvc.lock` y un remoto configurado en el repositorio. La ingesta también conserva un manifiesto complementario con archivo, filas, bytes y SHA-256. Esto permite reconstruir el snapshot y verificar su integridad.

3. Ingesta y feature engineering

La ingesta está disponible en `mibici/dataset.py`. Descarga los meses seleccionados y la nomenclatura desde el portal oficial, normaliza columnas, codificaciones y fechas, une el catálogo de estaciones y guarda el resultado limpio en Parquet. La etapa está declarada en `dvc.yaml`.

```
uv sync
uv run dvc repro --force dataset
```

`mibici/features.py` genera las variables reutilizables para las preguntas. Las particiones supervisadas son cronológicas y los features históricos se construyen únicamente con información disponible antes del horizonte para evitar fuga de información.

4. Modelos y métricas

Pregunta	Baseline	Candidato	Métricas
P1	Lag de demanda	RandomForestRegressor	MAE, RMSE, R^2
P2	Clase mayoritaria / presión	DecisionTreeClassifier	Accuracy, precision, recall, F1
P3	K-Means básico (escala + coords)	K-Means enriquecido / Aglomerativo	Silhouette, Davies-Bouldin, Calinski-Harabasz

Resultados con datos reales:

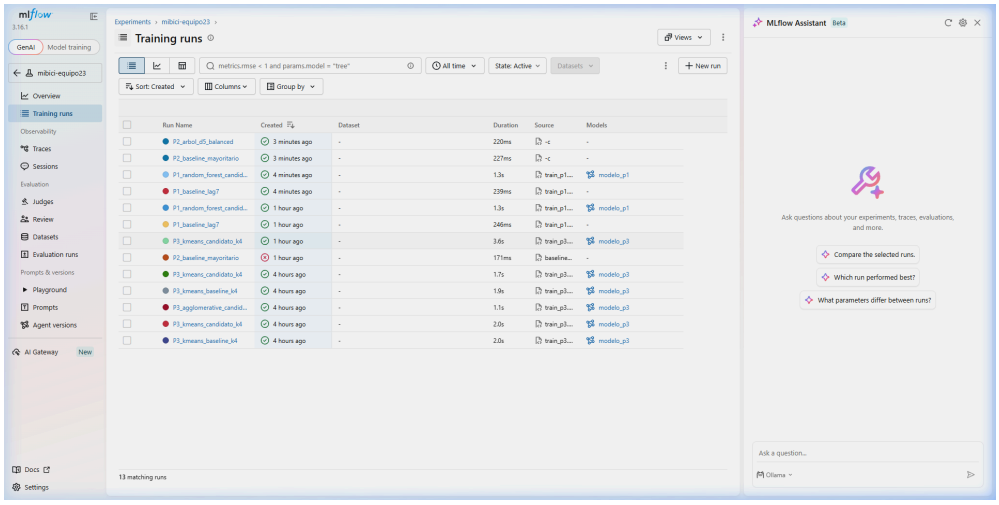
Run	Resultado
P1 baseline MAE	11.6304
P1 candidato MAE	6.5447
P1 candidato RMSE	12.4127
P2 baseline accuracy / F1	0.6244 / 0.7688
P2 candidato accuracy / F1	0.8282 / 0.8499
P3 baseline Silhouette	0.2990
P3 candidato Silhouette / DB	0.1834 / 1.7041
P3 candidato Aglomerativo Silhouette	0.1496

5. Arquitectura

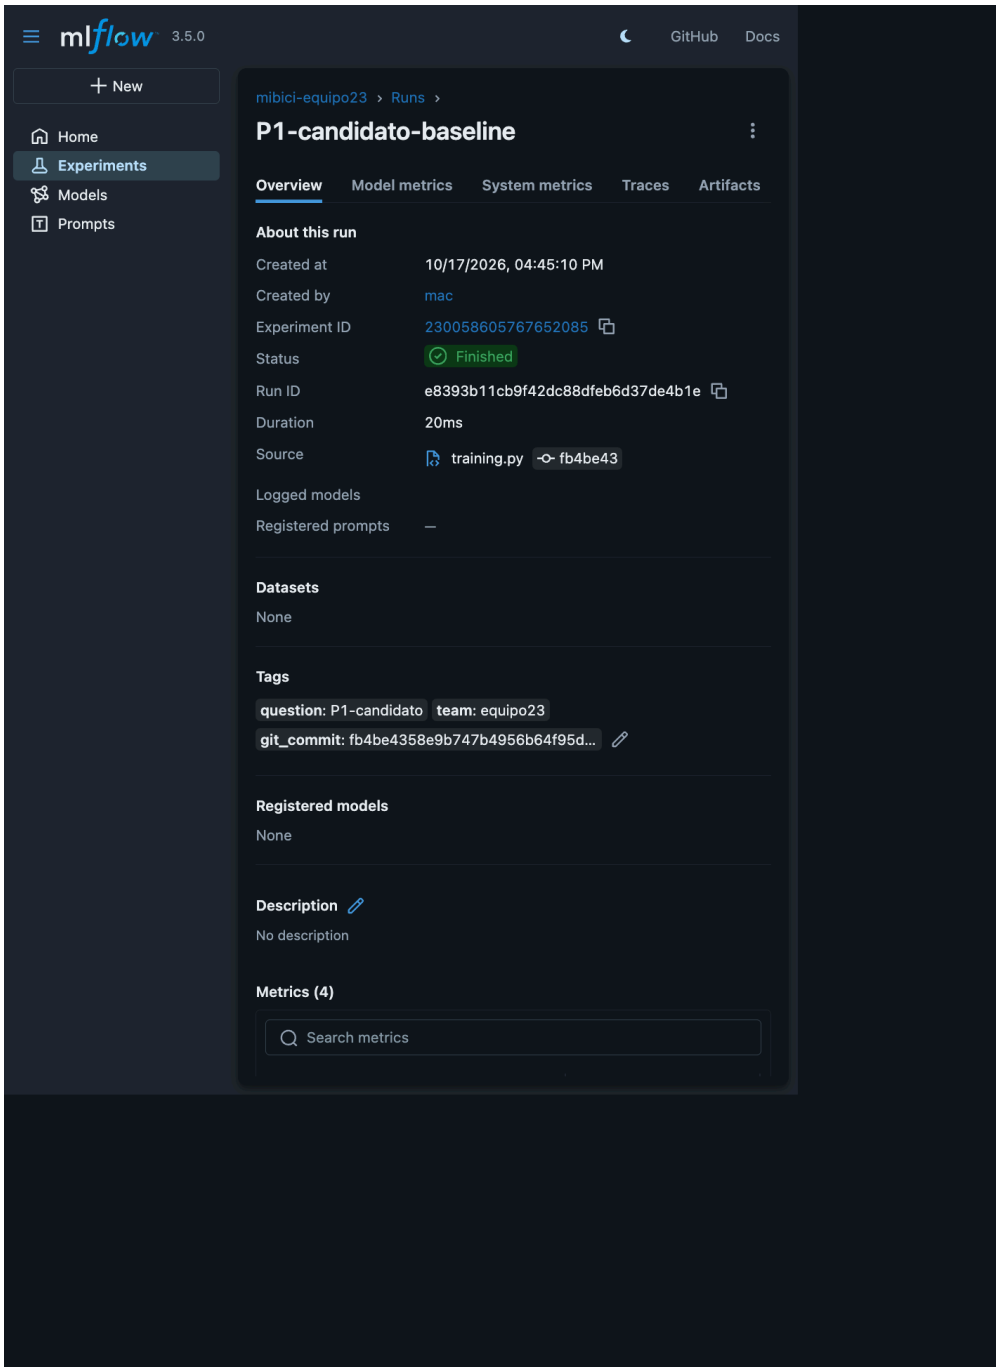
Portal MiBici → `mibici/dataset.py` → DVC → `data/processed/trips.parquet` → `mibici/features.py` → P1/P2/P3 → MLflow Tracking → `reports/figures/`. Git conserva código y documentación; DVC identifica el snapshot de datos y el manifiesto SHA-256 aporta una verificación adicional.

6. MLflow y reproducibilidad

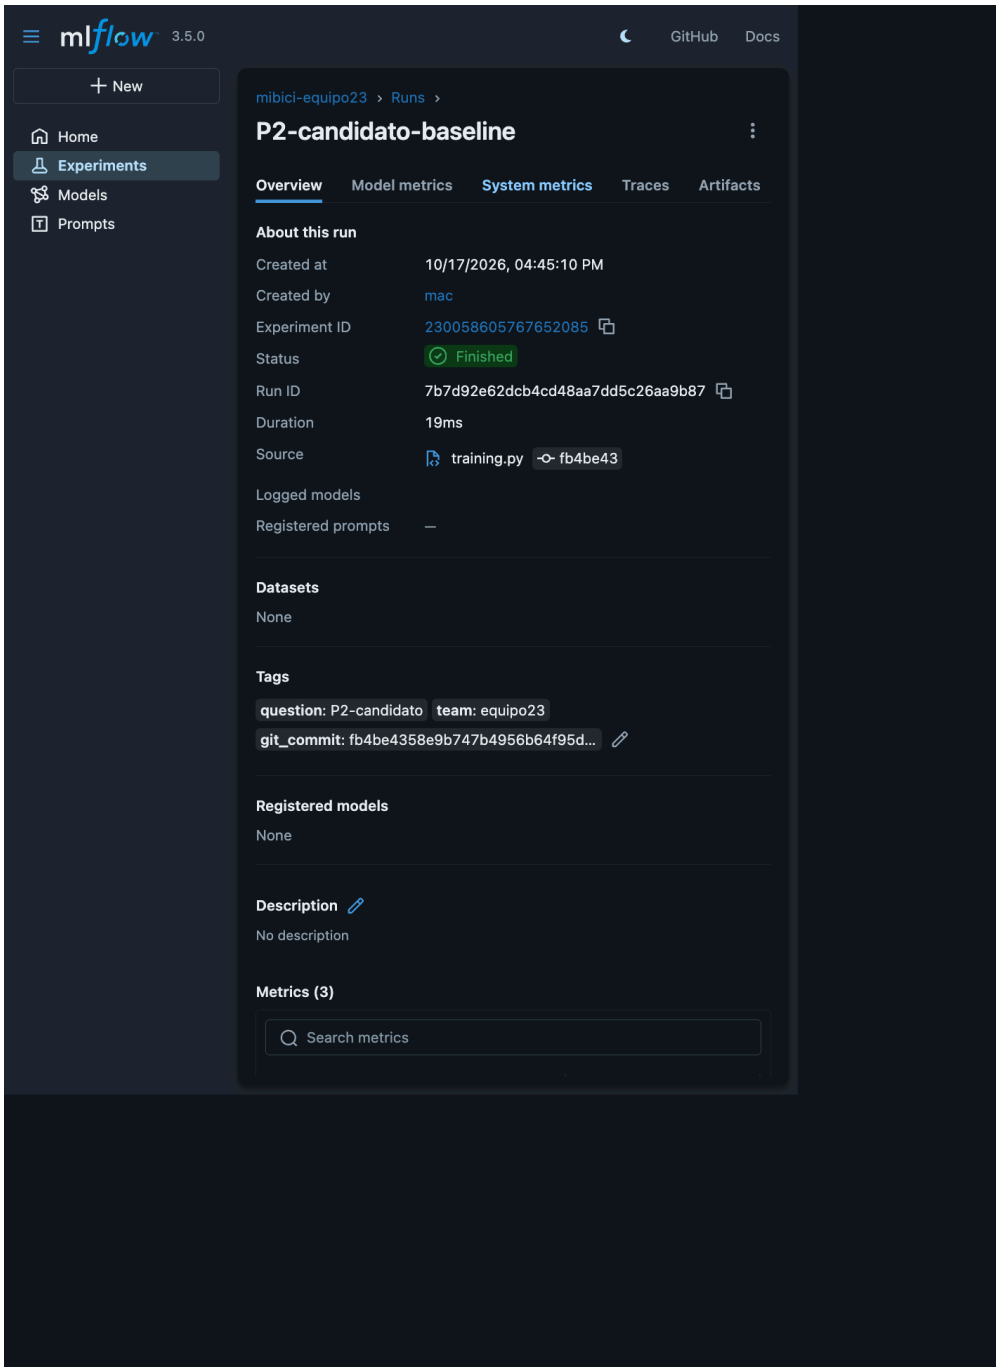
El experimento es `mibici-equipo23`. Incluye los runs P1-baseline, P1-candidato-baseline, P2-baseline, P2-candidato-baseline y P3-baseline. Cada run registra parámetros, métricas, etiquetas de equipo/pregunta/commit y artefactos.



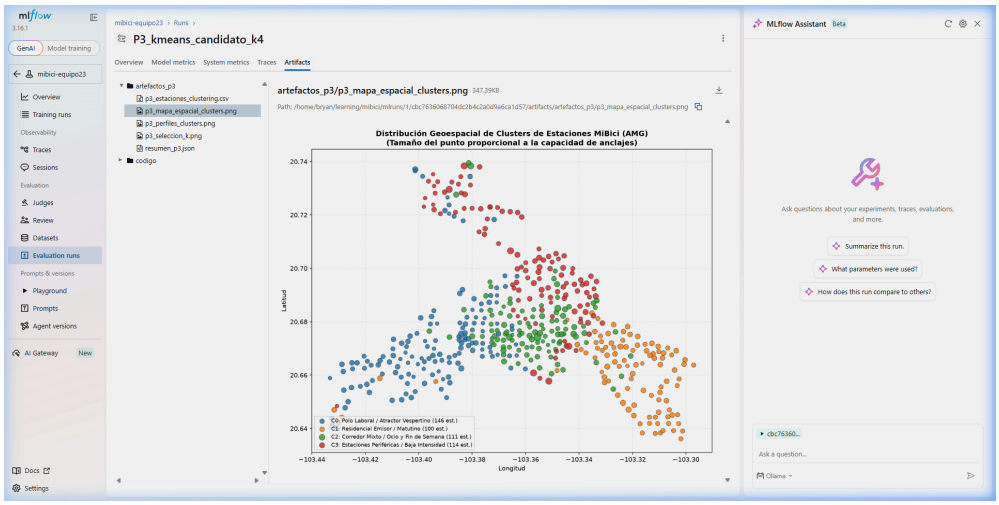
Lista de runs


mlflow 3.5.0
GitHub
Docs
New
Home
Experiments
Models
Prompts
mibici-equipo23 › Runs ›
P1-candidato-baseline
Overview
Model metrics
System metrics
Traces
Artifacts
About this run
Created at
10/17/2026, 04:45:10 PM
Created by
mac
Experiment ID
230058605767652085
Status
Finished
Run ID
e8393b11cb9f42dc88dfeb6d37de4b1e
Duration
20ms
Source
training.py
fb4be43
Logged models
Registered prompts
—
Datasets
None
Tags
question: P1-candidato
team: equipo23
git_commit: fb4be4358e9b747b4956b64f95d...
Registered models
None
Description
No description
Metrics (4)
Search metrics

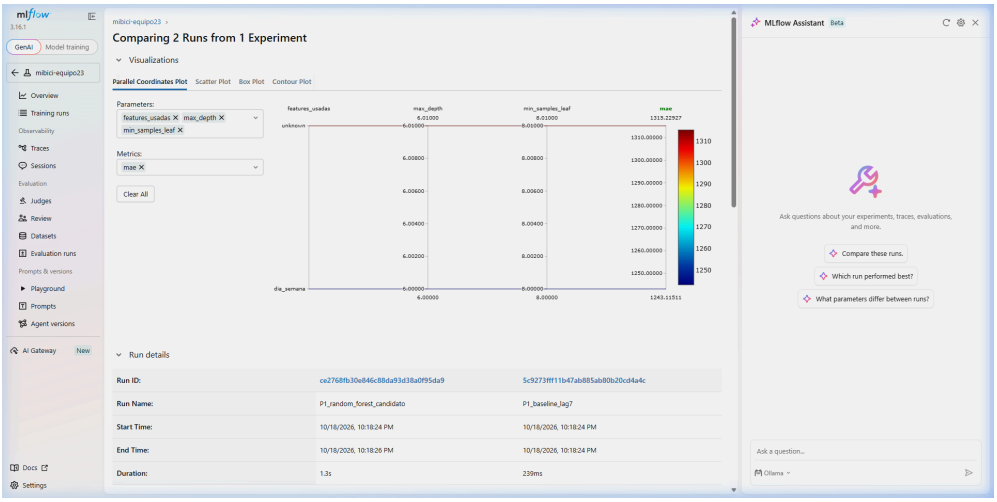
Detalle P1


mlflow 3.5.0
GitHub
Docs
New
Home
Experiments
Models
Prompts
mibici-equipo23 › Runs ›
P2-candidato-baseline
Overview
Model metrics
System metrics
Traces
Artifacts
About this run
Created at
10/17/2026, 04:45:10 PM
Created by
mac
Experiment ID
230058605767652085
Status
Finished
Run ID
7b7d92e62dcb4cd48aa7dd5c26aa9b87
Duration
19ms
Source
training.py
fb4be43
Logged models
Registered prompts
—
Datasets
None
Tags
question: P2-candidato
team: equipo23
git_commit: fb4be4358e9b747b4956b64f95d...
Registered models
None
Description
No description
Metrics (3)
Search metrics

Detalle P2


P3_kmeans_candidato_k4
artefactos_p3/p3_mapa_espacial_clusters.png
Distribución Geoespacial de Clusters de Estaciones MiBici (AMG)
(Tamaño del punto proporcional a la capacidad de anclajes)
Latitud
Longitud
MLflow Assistant

Detalle P3 y artefacto



Comparación de runs

7. Repositorio y entrega

El repositorio conserva la estructura Cookiecutter Data Science: `data/`, `notebooks/`, `mibici/`, `models/`, `reports/` y `references/`. El README documenta GitHub Flow, DVC, dependencias y reproducción. Los CSV, `mlruns/`, modelos serializados y credenciales están excluidos mediante `.gitignore`.

La entrega final debe incluir este PDF, el enlace al repositorio accesible para el profesor y la evidencia de colaboración de GitHub: rama principal protegida, commits de los cuatro integrantes, Pull Requests y revisiones.

Referencias

Consultar `referencias_apa7.md` y `fuentes.md` para las referencias completas y las fuentes mensuales.